

IA PRATIQUE — NUMÉRO 02

Titre : Data science sans maths : commencez par l'analyse

Durée : 20 minutes · Niveau : débutant · Coût : 0 €

Promesse : à la fin de cette session, vous aurez chargé un vrai jeu de données, produit 3 visualisations qui racontent une histoire, et répondu à une vraie question avec des chiffres.

> Le principe du numéro : la data science, ça commence par regarder les données. Les maths viendront plus tard — et peut-être jamais, selon le métier que vous viserez.

Ce que vous saurez faire dans 20 minutes

- Ouvrir un « notebook » gratuit dans votre navigateur (zéro installation)
- Charger un vrai jeu de données
- Poser 3 types de questions à vos données (comparer, distribuer, relier)
- Produire 3 graphiques qui répondent visuellement à ces questions

1. La leçon en 5 minutes : l'analyse avant les maths

Il y a un malentendu : beaucoup croient que la data science commence par les équations. C'est faux. Elle commence par une question et un tableau de données.

Un tableau de données, vous en manipulez déjà : une liste de courses, un planning, un tableur. La data science, c'est la même chose, en plus grand et avec des outils conçus pour ça. pandas est l'outil principal : une bibliothèque Python qui lit, trie, filtre et résume les tableaux. Vous n'aurez besoin d'aucune formule au-delà de la moyenne et du pourcentage — et pandas les calcule pour vous.

Les 3 questions de base que pose un analyste :

1. Comparer : « Ce groupe est-il différent de celui-ci ? » → graphique en barres
2. Distribuer : « Comment les valeurs sont-elles réparties ? » → histogramme
3. Relier : « Deux choses varient-elles ensemble ? » → nuage de points

C'est tout. Le reste (statistiques, tests, modèles) vient après, quand vous aurez besoin de répondre à des questions plus fines.

À retenir : vous n'apprenez pas les maths pour faire de la data. Vous apprenez à poser des questions et à lire des graphiques. Les maths s'invitent plus tard, seulement si vous en avez besoin.

2. L'atelier : pandas en 20 minutes, dans votre navigateur

On utilise Google Colab : un notebook Python gratuit qui tourne dans le navigateur. Rien à installer, rien à payer.

Étape 1 — Ouvrir votre atelier (2 minutes)

1. Allez sur colab.research.google.com et connectez-vous avec un compte Google.
2. « Nouveau notebook » → un carnet vide s'ouvre, avec une cellule de code.
3. Chaque bloc de code ci-dessous se colle dans une cellule (cliquez sur « + Code » pour en ajouter). Exécutez avec Maj + Entrée.

Étape 2 — Charger un vrai jeu de données (3 minutes)

Collez ceci dans la première cellule et exécutez :

```
# Installation de seaborn : elle contient des jeux de données réels
!pip install -q seaborn

import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Le jeu de données "tips" : les additions et pourboires d'un restaurant américain
df = sns.load_dataset("tips")
print("Nombre de lignes :", len(df))
df.head()
```

Ce que vous voyez : un tableau de 244 additions réelles, avec le montant (totalbill), le pourboire (tip), le jour (day), le moment (time) et la taille de la table (size). C'est un vrai jeu de données, collecté par un serveur qui notait ses additions en 1990. Un tableau + une question = de la data science.

Étape 3 — Faire connaissance avec les données (3 minutes)

```
# Un résumé automatique : chaque colonne, son type, ses valeurs manquantes
df.info()
```

```
# Les statistiques de base, calculées par pandas (moyenne, min, max...)
df.describe()
```

Lisez ça comme un humain : l'addition moyenne est d'environ 19,8 \$, le pourboire moyen 3 \$. On a déjà une histoire : le pourboire, c'est environ 15 % de l'addition. Vérifions avec une question de comparaison.

Étape 4 — Question 1, comparer : le pourboire moyen selon le jour (4 minutes)

```
# Graphique 1 : le pourboire moyen pour chaque jour de la semaine
sns.barplot(data=df, x="day", y="tip")
plt.title("Pourboire moyen par jour")
plt.show()
```

Ce que ça dit : le dimanche, les pourboires sont plus élevés. Question suivante : est-ce parce que les additions sont plus grosses, ou parce que les clients sont plus généreux ? Un analyste pose toujours la question d'après.

Étape 5 — Question 2, distribuer : la répartition des additions (4 minutes)

```
# Graphique 2 : la distribution des montants d'addition
sns.histplot(data=df, x="total_bill", bins=30, color="#064BD9")
plt.title("Répartition des additions")
plt.show()
```

Ce que ça dit : la plupart des additions se concentrent entre 10 \$ et 25 \$, avec une longue traîne de grosses additions rares. C'est la forme classique d'une distribution : on l'appelle « en cloche » quand elle est symétrique, ici elle penche à gauche.

Étape 6 — Question 3, relier : l'addition et le pourboire (4 minutes)

```
# Graphique 3 : le pourboire en fonction du montant de l'addition
sns.scatterplot(data=df, x="total_bill", y="tip")
plt.title("Pourboire en fonction de l'addition")
plt.show()
```

Ce que ça dit : plus l'addition est grosse, plus le pourboire est élevé — les points montent en diagonale. C'est une corrélation : deux variables qui varient ensemble. On peut même estimer la règle du restaurant : environ 15 % de l'addition.

3. Lire vos graphiques : le réflexe de l'analyste

Vous avez maintenant trois graphiques. Voici le raisonnement professionnel qui va avec :

1. Je compare (barres) → « le dimanche se distingue des autres jours ».
2. Je distribue (histogramme) → « la majorité des additions sont modestes ».
3. Je relie (nuage de points) → « les deux variables suivent la même direction ».

Chaque graphique répond à une question, et chaque réponse en pose une nouvelle. C'est exactement le travail d'analyse : un dialogue avec les données. La prochaine étape (compter, tester, modéliser) ne sert qu'à rendre ce dialogue plus précis — elle ne change pas la méthode.

> Piège à éviter : une corrélation n'est pas une cause. Les gros pourboires accompagnent les grosses additions, mais cela ne prouve pas que « payer plus rend généreux ». On dit : corrélation n'est pas causalité. Gardez ce réflexe en tête, il vous évitera 90 % des erreurs d'interprétation.

4. L'exercice de la semaine (15 minutes)

Mission : analysez un autre vrai jeu de données — les manchots de Palmer.

Les manchots (penguins), c'est le jeu de données le plus célèbre pour apprendre : 344 manchots de 3 espèces, mesurés dans la vraie vie par une équipe de recherche.

1. Reprenez votre notebook et remplacez tips par penguins :
df = sns.loaddataset("penguins")

2. Explorez avec `df.info()` et `df.head()`.
3. Répondez à ces 3 questions avec 3 graphiques (réutilisez les mêmes fonctions) :
 - Comparer : quelle espèce a le plus long bec en moyenne ? (`sns.barplot(data=df, x="species", y="billlengthmm")`)
 - Distribuer : comment se répartit la masse des manchots ? (`sns.histplot(data=df, x="bodymassg")`)
 - Relier : la longueur des ailes et la masse varient-elles ensemble ? (`sns.scatterplot(data=df, x="flipperlengthmm", y="bodymassg")`)

Critère de réussite : vous avez produit 3 graphiques ET vous pouvez raconter ce qu'ils montrent en 2 phrases chacun, à voix haute. Si vous savez le dire, vous savez le faire.

5. Ressources

- Google Colab : colab.research.google.com — votre atelier gratuit, sans installation.
- Aide-mémoire pandas (en français) : « pandas cheat sheet » — imprimez-le, c'est le seul document dont vous aurez besoin pendant des mois.
- Seaborn gallery : seaborn.pydata.org/examples — des dizaines de graphiques prêts à copier.
- Glossaire express :
- DataFrame : le tableau de pandas (lignes + colonnes).
- Series : une seule colonne de ce tableau.
- `head()` / `info()` / `describe()` : vos 3 premiers réflexes (voir, comprendre, résumer).
- Histogramme : la répartition des valeurs d'une colonne.
- Corrélation : deux variables qui varient ensemble (positif : même direction ; négatif : directions opposées).
- Causalité : l'une provoque l'autre. Beaucoup plus rare que la corrélation.

À la semaine prochaine

Vous savez charger des données et les faire parler. La semaine prochaine : « Gagner de l'argent avec l'IA : les 5 pistes qui marchent en 2026 » — avec les tarifs honnêtes et la vérité sur le travail nécessaire. Aucune promesse de richesse facile : uniquement des chemins réels.

En attendant : ouvrez un fichier qui vous appartient — vos dépenses du mois, vos notes de cours — et posez-lui une question de comparaison. La compétence, c'est de l'habitude.

— IA Pratique · « L'IA qui se retient, c'est l'IA qu'on applique. »